

Memoria Práctica 2: Spaceship-Titanic

Juan Luis González Rodríguez & Rocío González Martínez

2022-06-06

Índice

1 Contexto	2
1.1 Descripción del Dataset	2
1.2 ¿Por qué es importante y qué pregunta/problema pretende responder?	3
2 Integración y selección de los datos de interes.	3
3 Limpieza de los Datos.	4
3.1 Tratamiento valores nulos.	4
3.2 Tratamiento valores extremos.	5
4 Análisis de los datos	6
4.1 Selección de los grupos de datos	6
4.2 Comprobación de la normalidad y homogeneidad de la varianza	9
4.3 Aplicación de pruebas estadísticas	15
4.3.1 Análisis de Correlaciones	15
4.3.2 Contraste de hipótesis	16
4.3.3 Modelo de regresión logarítmica	17
5 Tablas y gráficas	19
6 Resolución del problema y conclusiones.	19
7 Código	19

1 Contexto

1.1 Descripción del Dataset

El dataset *Spaceship Titanic* [1]. Este dataset es parte de la competición homónima y tiene por objetivo crear un algoritmo para predecir qué pasajeros han desaparecido al colisionar una nave espacial denominada Titanic con una anomalía espaciotemporal. Con el conjunto de datos, se pretende predecir si el pasajero ha desaparecido o no, para enviar a un equipo a rescatarlo. Para ello, se facilitan 2 ficheros (separados por entrenamiento y test), Se usará el fichero *train.csv* en uno para limpiar todos los registros y posteriormente se usará este para entrenar al modelo. Con el fichero test podremos probar el modelo (no incluye la variable objetivo).

Descripción de **Train.csv**: Conjunto de datos con información de unos 8 700 pasajeros. Este consta de los campos que se especifican más abajo.

Nombre	Tipo	Descripción
PassengerId	chr	Identificador de cada pasajero. El formato es gggg_pp (gggg hace referencia al grupo de pasajeros y pp al número dentro del grupo). Normalmente los miembros del grupo son familia.
HomePlanet	factor	Planeta de origen del pasajero.
CryoSleep	logical	Indica si el pasajero está en animación suspendida durante el viaje o no.
Cabin	chr	Indican la cabina del pasajero. El formato es “plataforma/numero/lado”. Lado será P o S
Destination	factor	Indica el nombre del planeta de destino del pasajero.
Age	integer	Indica la edad biológica del pasajero en años en el momento del viaje.
VIP	logical	Indica si el pasajero ha pagado por un servicio VIP o no
RoomService, FoodCourt, ShoppingMall, Spa, VRDeck	numeric	Indica la cantidad de dinero que el pasajero ha gastado en cada uno de los servicios
Name	chr	Indica el nombre y apellido del pasajero
Transported	logical	Variable objetivo, indica si el pasajero ha sido transportado a otra dimensión o no (es decir si ha desaparecido).

La estructura del dataset es la siguiente:

```
## 'data.frame':   8693 obs. of  14 variables:
## $ PassengerId : chr  "0001_01" "0002_01" "0003_01" "0003_02" ...
## $ HomePlanet  : Factor w/ 4 levels "", "Earth", "Europa", ...: 3 2 3 3 2 2 2 2 2 3 ...
## $ CryoSleep   : logi  FALSE FALSE FALSE FALSE FALSE FALSE ...
## $ Cabin       : chr   "B/O/P" "F/O/S" "A/O/S" "A/O/S" ...
## $ Destination : Factor w/ 4 levels "", "55 Cancri e", ...: 4 4 4 4 4 3 4 4 4 2 ...
## $ Age         : int   39 24 58 33 16 44 26 28 35 14 ...
## $ VIP         : logi  FALSE FALSE TRUE FALSE FALSE FALSE ...
## $ RoomService : num   0 109 43 0 303 0 42 0 0 0 ...
```

```
## $ FoodCourt : num 0 9 3576 1283 70 ...
## $ ShoppingMall: num 0 25 0 371 151 0 3 0 17 0 ...
## $ Spa : num 0 549 6715 3329 565 ...
## $ VRDeck : num 0 44 49 193 2 0 0 NA 0 0 ...
## $ Name : chr "Maham Ofracculy" "Juanna Vines" "Altark Susent" "Solam Susent" ...
## $ Transported : logi FALSE TRUE FALSE FALSE TRUE TRUE ...
```

1.2 ¿Por qué es importante y qué pregunta/problema pretende responder?

El objetivo que se persigue con el proyecto es el de, partiendo del conjunto de datos anteriormente comentado, desarrollar un modelo supervisado que permita responder a la pregunta: **¿Ha desaparecido el pasajero que se indica?**

Con ello, la tripulación podrá dirigir los esfuerzos de una manera más eficiente y maximizar las vidas salvadas.

2 Integración y selección de los datos de interes.

Solo hay 1 fichero de origen, por lo que no hay que combinar los datos de diferentes fuentes.

Como ya se tiene a los usuarios identificados a los usuarios en base a los identificadores, no es necesario almacenar sus nombres de cara al análisis. Por otro lado, de los campos *Passenger_id* y *Cabin* se pueden extraer aún más campos como el grupo y número dentro del grupo en el primer caso y la plataforma, número de cabina y lado en el segundo.

Se elimina la variable *Name* y se crean las nuevas variables derivadas.

Tras crear las nuevas variables derivadas se elimina *Cabin* porque ya tenemos su información separada. *PassengerId* no se eliminará porque sirve para identificar los registros. Se muestra un resumen de los campos con la función *summary*.

```
## PassengerId      HomePlanet      CryoSleep      Destination
## Length:8693      : 201      Mode :logical      : 182
## Class :character  Earth :4602      FALSE:5439      55 Cancr e :1800
## Mode :character   Europa:2131      TRUE :3037      PSO J318.5-22: 796
##                      Mars :1759      NA's :217      TRAPPIST-1e :5915
##
##
##
##      Age      VIP      RoomService      FoodCourt
## Min. : 0.00      Mode :logical      Min. : 0.0      Min. : 0.0
## 1st Qu.:19.00      FALSE:8291      1st Qu.: 0.0      1st Qu.: 0.0
## Median :27.00      TRUE :199      Median : 0.0      Median : 0.0
## Mean :28.83      NA's :203      Mean : 224.7      Mean : 458.1
## 3rd Qu.:38.00      3rd Qu.: 47.0      3rd Qu.: 76.0
## Max. :79.00      Max. :14327.0      Max. :29813.0
## NA's :179      NA's :181      NA's :183
## ShoppingMall      Spa      VRDeck      Transported
## Min. : 0.0      Min. : 0.0      Min. : 0.0      Mode :logical
## 1st Qu.: 0.0      1st Qu.: 0.0      1st Qu.: 0.0      FALSE:4315
## Median : 0.0      Median : 0.0      Median : 0.0      TRUE :4378
## Mean : 173.7      Mean : 311.1      Mean : 304.9
## 3rd Qu.: 27.0      3rd Qu.: 59.0      3rd Qu.: 46.0
## Max. :23492.0      Max. :22408.0      Max. :24133.0
## NA's :208      NA's :183      NA's :188
## PassengerGroup      PassengerNumInGroup      CabinPlatform      CabinNumber
## Length:8693      01 :6217      F :2794      Min. : 0.0
## Class :character    02 :1412      G :2559      1st Qu.: 167.2
## Mode :character      03 : 571      E : 876      Median : 427.0
##                      04 : 231      B : 779      Mean : 600.4
##                      05 : 128      C : 747      3rd Qu.: 999.0
##                      06 : 75      (Other): 739      Max. :1894.0
```

```
##                (Other):  59          NA's    : 199    NA's    :199
## CabinSide
## P      :4206
## S      :4288
## NA's: 199
##
##
##
##
```

Cabe destacar que en *HomePlanet* y en *Destination* hay campos con valores vacíos que no se han considerado como NA's. Por otro lado, Hay algunos campos que presenta NA's que podrán tratarse o desestimarse. También se observan valores extremos en algunos campos.

3 Limpieza de los Datos.

En este apartado se tratará de mejorar la calidad de los datos presentes en base a la falta de calidad. Por límite de extensión del proyecto, nos centraremos en el tratamiento de outliers y de valores nulos.

3.1 Tratamiento valores nulos.

Como se puede ver en el Summary del apartado anterior, en muchos de los campos del conjunto de datos hay registros vacíos que se deben tratar. El listado de campos afectados es el siguiente:

1. HomePlanet
2. Destination
3. Age
4. CryoSleep
5. VIP
6. RoomService
7. FoodCourt
8. ShoppingMall
9. Spa
10. VRDeck
11. CabinPlatform, CabinNumber, CabinSide

En los dos primeros casos, se remapean los registros en blanco de los campos *HomePlanet* y *Destination* por el valor *Unknown*. Con esto, no perdemos información y evitamos confundir a las personas que interpreten los resultados.

De los otros casos, siguen existiendo el siguiente número de valores nulos.

```
##      PassengerId      HomePlanet      CryoSleep      Destination
##           0           0           217           0
##      Age           VIP      RoomService      FoodCourt
##      179          203          181          183
##      ShoppingMall      Spa      VRDeck      Transported
##           208          183          188           0
##      PassengerGroup PassengerNumInGroup      CabinPlatform      CabinNumber
##           0           0           199          199
##      CabinSide
##           199
```

En primer lugar, se eliminarán los registros del conjunto de datos que contengan un valor vacío en los campos *Age* y *CryoSleep*, así como en los campos *CabinPlatform*, *CabinNumber* y *CabinSide*, ya que el volumen de registros afectados es muy pequeño en comparación con el total de registros del dataset:

También eliminamos del conjunto de datos los registros en los que no se informe el campo VIP, pues los nulos de los campos numéricos se informarán a partir de este.

Observemos ahora, en un dataframe en el que eliminásemos todos los registros nulos, cómo se comporta el gasto de los diferentes campos en función de si el pasajero es VIP:

```
## # A tibble: 2 x 6
##   'dfGr$VIP' RoomService FoodCourt ShoppingMall Spa VRDeck
##   <lgl>      <dbl>      <dbl>      <dbl> <dbl> <dbl>
## 1 FALSE      221.      436.      177.  303.  281.
## 2 TRUE       350.     1932.      225.  776. 1217.
```


Como se puede ver en la tabla anterior, la diferencia entre el gasto de un pasajero VIP y uno no VIP es considerable. Por esta razón, se decide informar los valores nulos de campos asociados a gastos a partir de la media del gasto en el grupo VIP y no VIP.

Después de estos tratamientos ya podemos observar cómo el Dataset aparece limpio de valores vacíos:

```
##      PassengerId      HomePlanet      CryoSleep      Destination
##           0           0           0           0
##      Age           VIP      RoomService      FoodCourt
##           0           0           0           0
##      ShoppingMall      Spa      VRDeck      Transported
##           0           0           0           0
##      PassengerGroup PassengerNumInGroup CabinPlatform CabinNumber
##           0           0           0           0
##      CabinSide
##           0
```

3.2 Tratamiento valores extremos.

Para realizar el análisis de valores extremos, se representan los valores de los campos numéricos en un BoxPlot:



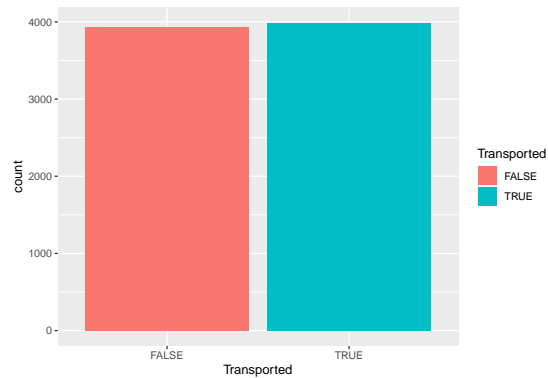
Los valores alejados que se pueden ver en el gráfico anterior sí parecen valores atípicos dentro del conjunto de datos, pero en ningún caso se consideran en este proyecto valores extremo, ya que como se puede observar, la distribución de los datos está por encima de los cuartiles. Estos datos atípicos que se comentan, siguen siendo representativos de la variedad de la muestra, y por tanto formarán parte del conjunto de datos que se utilizará para entrenar al modelo.

4 Análisis de los datos

4.1 Selección de los grupos de datos

Dentro del conjunto de datos, encontramos un campo que será nuestra variable objetivo a predecir en el modelo que se quiere construir. Esta variable es *Transported*, e indica como se comentaba en el primer apartado, si un pasajero ha desaparecido después de colisionar. Por tanto, los grupos de datos a analizar son, por un lado los pasajeros transportados, y por otro, los no transportados.

Para realizar un primer análisis exploratorio, comprobamos en primer lugar el volumen de datos distribuidos en nuestra variable objetivo (*Transported*):




Como vemos, la mitad de los datos indican que el pasajero desapareció, y la otra mitad indica lo contrario.

```
##   Transported   n
## 1      FALSE 3936
## 2       TRUE 3989
```

¿Cómo se relaciona esta variable con el resto de campos del conjunto de datos? ¿Se ve afectada por alguna de las otras variables?

Para ello, crearemos un nuevo campo que mida el gasto total de cada pasajero:


Si miramos la relación entre esta nueva variable y la variable objetivo, obtenemos lo siguiente:




Lo que indica el gráfico anterior es que la mayoría de pasajeros tienen un gasto más cercano a los valores pequeños. Pero está claro que de esta manera no se puede apreciar si existe alguna relación entre ambos campos. Por esta razón, procedemos a discretizar *TotalExpenses* según el método KN:

```
##
##      [0,3.2e+03) [3.2e+03,1.14e+04] [1.14e+04,3.6e+04]
##      6957      840      128
```

Si se discretiza mediante KM, la distribución que seguiría es la siguiente:

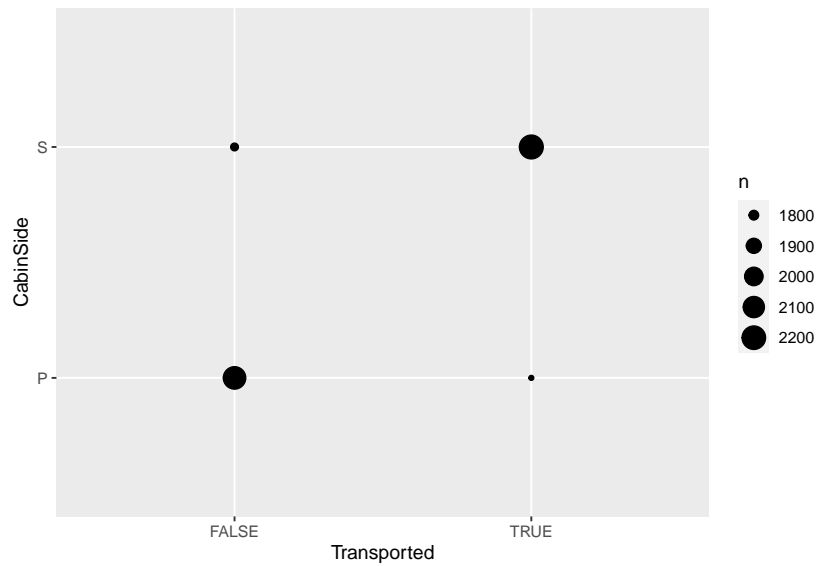


Y se puede, mediante un gráfico de barras, ver la relación entre la variable anterior y la variable *Transported*.



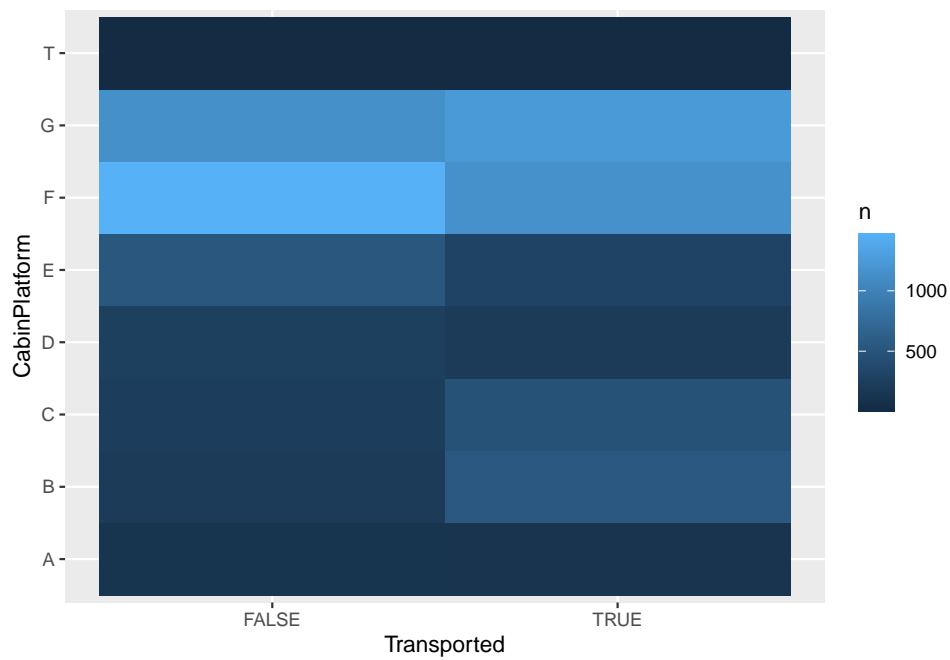
En este caso, no parece haber ninguna relación entre ambas variables, ya que el mayor porcentaje de pasajeros transportados y no transportados estaban en el primer segmento de gasto.

Sí parece haber una correlación entre las variables *CabinSide* y *Transported*:




En este caso se ve claramente cómo el volumen grande de pasajeros transportados estaban en el lado S, mientras que los no transportados pertenecían al lado P.

No es tan claro, sin embargo, la afectación de la plataforma de la cabina en la transportación de los pasajeros:



Por último, comprobamos también la relación entre la variable objetivo *Transported* y la variable *CryoSleep*, que indicaba si el pasajero estaba en animación suspendida o no:

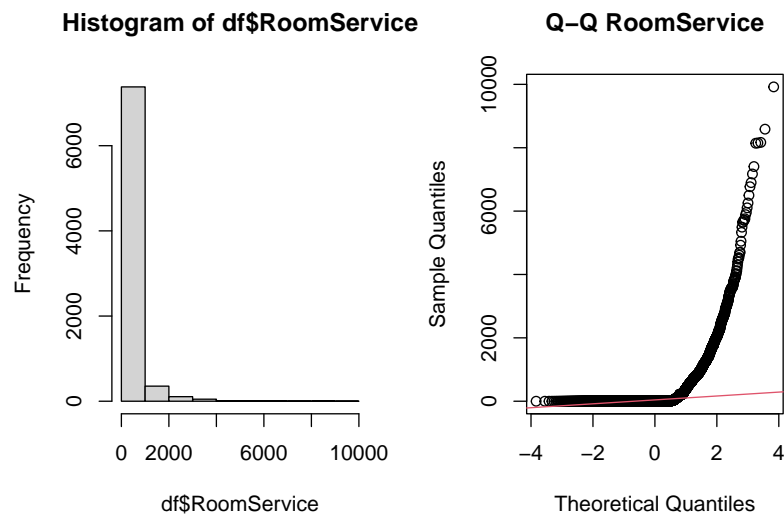


En este caso, aunque no es igual de claro que con la variable *CabinSide*, también parece haber una correlación entre las variables.

4.2 Comprobación de la normalidad y homogeneidad de la varianza

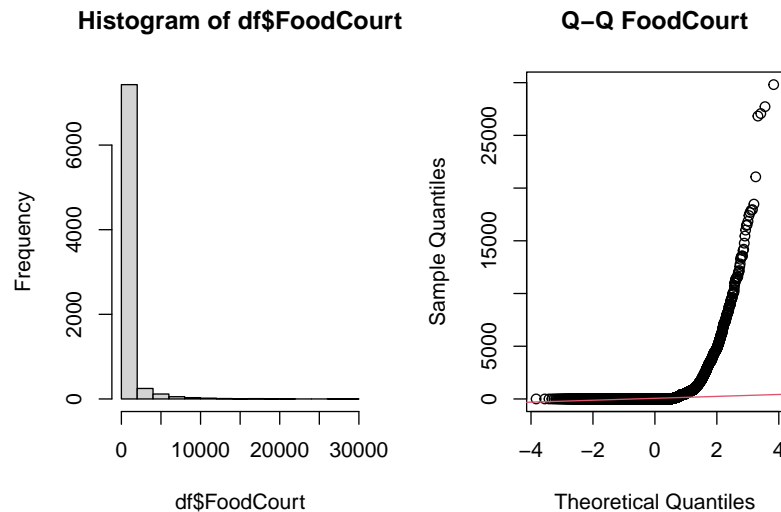
Debido a la naturaleza de las variables, se deberá estudiar la normalidad y varianza para las variables numéricas. No tiene sentido estudiar si se distribuye normalmente o con que varianza lo hace una variable categórica. Es decir, se estudiará sobre las variables *Age*, *RoomService*, *FoodCourt*, *ShoppingMall*, *Spa* y *VRDeck*.

A continuación se detalla el **estudio de la normalidad**. Debido a que, la cantidad de registros es superior a 5 000, se usará el test de normalidad de *Anderson-Darling*, ya que el test de *Shapiro-Wilk* tiene como limitación un valor máx. de 5 000 registros.




```
##
## Anderson-Darling normality test
##
## data: df$RoomService
## A = 1696, p-value < 2.2e-16
```

Gráficamente se observa que no sigue una distribución normal. Si realizamos el test de normalidad de *Anderson-Darling* nos da un p-valor $< 0,05$. Por lo que se rechaza la hipótesis nula que indica que los datos siguen una distribución normal.




```
##
## Anderson-Darling normality test
##
## data: df$FoodCourt
## A = 1946.7, p-value < 2.2e-16
```

Gráficamente se observa que no sigue una distribución normal. Si realizamos el test de normalidad de *Anderson-Darling* nos da un p-valor $< 0,05$. Por lo que se rechaza la hipótesis nula que indica que los datos siguen una distribución normal.



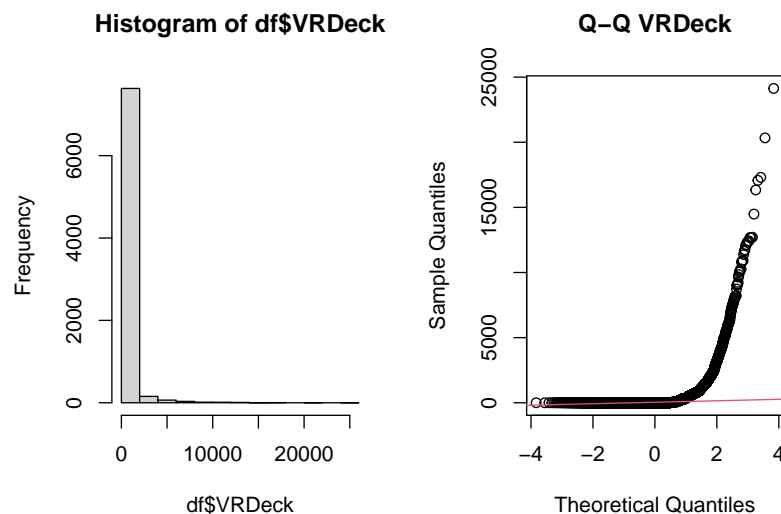
```
##
## Anderson-Darling normality test
##
## data: df$ShoppingMall
## A = 1788.3, p-value < 2.2e-16
```

Gráficamente se observa que no sigue una distribución normal. Si realizamos el test de normalidad de *Anderson-Darling* nos da un p-valor $< 0,05$. Por lo que se rechaza la hipótesis nula que indica que los datos siguen una distribución normal.




```
##
## Anderson-Darling normality test
##
## data: df$Spa
## A = 1937.5, p-value < 2.2e-16
```

Gráficamente se observa que no sigue una distribución normal. Si realizamos el test de normalidad de *Anderson-Darling* nos da un p-valor $< 0,05$. Por lo que se rechaza la hipótesis nula que indica que los datos siguen una distribución normal.



```
##
## Anderson-Darling normality test
##
## data: df$VRDeck
## A = 1967.5, p-value < 2.2e-16
```

Gráficamente se observa que no sigue una distribución normal. Si realizamos el test de normalidad de *Anderson-Darling* nos da un p-valor $< 0,05$. Por lo que se rechaza la hipótesis nula que indica que los datos siguen una distribución normal.




```
##
## Anderson-Darling normality test
##
## data: df$Age
## A = 46.535, p-value < 2.2e-16
```

Gráficamente se observa que no sigue del todo una distribución normal, hay más datos de los esperados en la parte izquierda de la distribución, por lo que aunque se aproxima no aporta información segura. Si realizamos un test formal de normalidad, como el de *Anderson-Darling*, indica un p-valor $< 0,05$. Por lo que se rechaza la hipótesis nula que indica que los datos siguen una distribución normal. Si en los siguientes análisis se requiere que los datos sigan una distribución normales, se deberá de proceder a corregir esta.

Tras comprobar la normalidad, se procede a realizar el **análisis de homocedasticidad**. Es decir, se comprueba la igualdad de varianza entre los grupos que se van a comparar. Como los datos no siguen una distribución normal no se aplica el test de *Levene*. En su defecto se usará el test de *Fligner-Killeen*. Con ello comprobaremos si la varianza entre los dos grupos (pasajeros transportados y no transportados) es la misma o no.


Aplicamos a todas las variables numéricas:

```
##
## Fligner-Killeen test of homogeneity of variances
##
## data: RoomService by Transported
## Fligner-Killeen:med chi-squared = 2575.7, df = 1, p-value < 2.2e-16
```




Se rechaza la hipótesis nula de homocedasticidad. Por lo que la variable *RoomService* presenta varianzas estadísticamente diferentes para los pasajeros transportados y los no transportados. Se puede observar gráficamente como, los gráficos Boxplot apuntan a la misma conclusión. Se ha establecido en el plot un valor máx. de la variable del eje y como 2000 para observar mejor los IQR.

```
##
## Fligner-Killeen test of homogeneity of variances
##
## data: FoodCourt by Transported
## Fligner-Killeen:med chi-squared = 100.61, df = 1, p-value < 2.2e-16
```




Se rechaza la hipótesis nula, la variable *FoodCour* presenta heterocestasicidad en los grupos definidos por *Transported*. Se puede observar gráficamente como, los gráficos Boxplot apuntan a la misma conclusión. Se ha establecido en el plot un valor máx. de la variable del eje y como 500 para observar mejor los IQR.

```
##
## Fligner-Killeen test of homogeneity of variances
##
## data: ShoppingMall by Transported
## Fligner-Killeen:med chi-squared = 183.47, df = 1, p-value < 2.2e-16
```




Se rechaza la hipótesis nula de homocedasticidad. Por lo que la variable *ShoppingMall* presenta varianzas estadísticamente diferentes para los pasajeros transportados y los no transportados. Se puede observar gráficamente como, los gráficos Boxplot apuntan a la misma conclusión. Se ha establecido en el plot un valor máx. de la variable del eje y como 300 para observar mejor los IQR.

```
##
## Fligner-Killeen test of homogeneity of variances
##
## data: Spa by Transported
## Fligner-Killeen:med chi-squared = 2572.1, df = 1, p-value < 2.2e-16
```




Se rechaza la hipótesis nula, la variable *Spa* presenta heterocedasticidad en los grupos definidos por *Transported*. Se puede observar gráficamente como, los gráficos Boxplot apuntan a la misma conclusión. Se ha establecido en el plot un valor máx. de la variable del eje y como 1500 para observar mejor los IQR.

```
##
## Fligner-Killeen test of homogeneity of variances
##
## data: VRDeck by Transported
## Fligner-Killeen:med chi-squared = 2399.1, df = 1, p-value < 2.2e-16
```



Se rechaza la hipótesis nula, la variable *VRDeck* presenta heterocedasticidad en los grupos definidos por *Transported*. Se puede observar gráficamente como, los gráficos Boxplot apuntan a la misma conclusión. Se ha establecido en el plot un valor máx. de la variable del eje y como 1200 para observar mejor los IQR.

```
##
## Fligner-Killeen test of homogeneity of variances
##
## data: Age by Transported
## Fligner-Killeen:med chi-squared = 34.571, df = 1, p-value = 4.109e-09
```



Aunque gráficamente parece que la varianza es homogénea para los dos grupos de la variable *Age* definidos por *Transported*, el test de *Fligner-Killeen* apunta a que no son iguales. El p-valor apartado es inferior a 0.05 por lo que se rechaza la hipótesis nula de igualdad de varianzas.

Por lo que se afirma que **ninguno de los campos numéricos sigue una distribución normal, ni presentan homocedasticidad** para los dos grupos definidos por la variable *Transported*. Se observa en cuanto a la distribución normal. Que en todas las variables (salvo en *Age*) el grupo asignado como “TRUE” tiene muchos más valores en 0 (lo que indica que no han gastado nada en esos servicios) que el asignado como “FALSE.”

4.3 Aplicación de pruebas estadísticas

4.3.1 Análisis de Correlaciones

Para realizar el análisis de correlaciones, en primer lugar se creará un conjunto de datos nuevo a partir del anterior, que contenga las mismas variables pero transformadas todas a numéricas:

```


##   HomePlanet CryoSleep Destination Age VIP RoomService FoodCourt ShoppingMall
## 1           3         0           4 39   0           0           0           0
## 2           2         0           4 24   0          109           9          25
## 3           3         0           4 58   1           43          3576          0
##   Spa VRDeck Transported CabinPlatform CabinNumber CabinSide
## 1    0     0           0           3           0           3
## 2 549    44           1           2           0           2
## 3 6715   49           0           3           0           3

##   HomePlanet CryoSleep Destination Age VIP RoomService FoodCourt ShoppingMall
## 1           3         0           4 39   0           0           0           0
## 2           2         0           4 24   0          109           9          25
## 3           3         0           4 58   1           43          3576          0
##   Spa VRDeck Transported CabinPlatform CabinNumber CabinSide
## 1    0     0           0           3           0           3
## 2 549    44           1           2           0           2
## 3 6715   49           0           3           0           3

```

Una vez se tiene el dataset preparado, se calcula la correlación entre todas las variables, teniendo en cuenta que el análisis de Normalidad y Homocedasticidad ha salido negativo en ambos casos (ni los datos son normales ni se cumple la homocedasticidad). Por tanto, se usa el método de Spearman.

Se puede ver que no parece haber correlación entre ninguna variable. A continuación, se presentan este coeficiente de correlación en un gráfico:



4.3.2 Contraste de hipótesis

Se realizará un contraste de hipótesis en el que se estudiará si el gato total de dos submuestras, siendo una las personas con TRUE en Transported y las segundas las personas con FALSE.

En primer lugar, se crea una variable denominada *amountSpent*, esta será la suma de todas las variables relacionadas con el gasto.

Con esta, se plantea la pregunta de investigación:

¿Es diferente la media del total gastado de las personas transportadas μ_1 que la media del total gastado de las personas no transportadas μ_2 ?

La formulación del contraste de hipótesis nula y alternativa es la siguiente:

$$H_0 : \mu_1 = \mu_2$$

ID	Transported	Prediction
0004_01	TRUE	FALSE
0007_01	TRUE	TRUE
0008_02	TRUE	TRUE
0009_01	TRUE	TRUE
0016_01	TRUE	TRUE
0020_01	FALSE	TRUE

$$H_1 : \mu_1 \neq \mu_2$$

Como las muestras no siguen una distribución normal se usará un test para realizar el contraste NO paramétrico de dos muestras independientes. Este test será el **test de suma de rangos de Wilcoxon**.

```
##
## Wilcoxon rank sum test with continuity correction
##
## data: amountSpenteNOTransported and amountSpenteTransported
## W = 11486818, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
```

Con un p-valor inferior al valor de significancia de 0.05, no hay evidencia suficiente para aceptar la hipótesis nula. Por lo que se puede concluir que la media de la cantidad total de dinero gastada por las personas Transportadas y las No transportadas no es estadísticamente igual.

4.3.3 Modelo de regresión logarítmica

Se usará un modelo de regresivo logística que permitirá identificar a los pasajeros entre transportados o no transportados. Para ello hará uso de las variables explicativas que determinarán en la medida de lo posible si estos pasajeros toman un valor u otro.

Se parten los datos en *df* para entrenar al modelo con un 70% de los casos y en *df_validation* para medir la bondad del modelo con el 30% restante.

Aunque no se incluye en la práctica por motivos de extensión. Se han realizado análisis previos y se ha determinado que hay variables que empeoran el modelo, por lo que estas se eliminan en el entrenamiento y en la validación.

Se entrena el modelo con el dataset previamente creado. Se presupone que las variables no son variables de confusión y no presentan interacción entre ellas.

```
## glm(formula = Transported ~ ., family = binomial(link = "logit"),
##      data = df1)

## (Intercept) CryoSleepTRUE RoomService FoodCourt ShoppingMall
## -0.4757024015 1.8418603169 -0.0012826905 0.0007306835 0.0007306236
## Spa VRDeck CabinNumber CabinSideS
## -0.0015130232 -0.0013227005 -0.0001478249 0.5529837634
```

A continuación se evalúa el mismo. Para ello se predicen los valores del conjunto *df_validation* y se comparan con los valores reales del mismo.

Se convierten las variables *Transported* (valor real) y *Prediction* (valor predicho) y se mide la bondad del modelo con la matriz de confusión mediante la función **confusionMatrix*).

```
## Confusion Matrix and Statistics
##
##              Reference
## Prediction FALSE TRUE
```

```


##      FALSE   924   256
##      TRUE    239   957
##
##              Accuracy : 0.7917
##              95% CI : (0.7748, 0.8078)
##      No Information Rate : 0.5105
##      P-Value [Acc > NIR] : <2e-16
##
##              Kappa : 0.5833
##
##  McNemar's Test P-Value : 0.4721
##
##      Sensitivity : 0.7945
##      Specificity : 0.7890
##      Pos Pred Value : 0.7831
##      Neg Pred Value : 0.8002
##      Prevalence : 0.4895
##      Detection Rate : 0.3889
##      Detection Prevalence : 0.4966
##      Balanced Accuracy : 0.7917
##
##      'Positive' Class : FALSE
##

```

La clase positiva se categoriza como FALSE (no desaparecido).

Se observa una buena predicción de las clases. Con una exactitud del 79,17%. La tasa de positivos que se han asignado como positivos es del 79,45%. mientras que los negativos identificado como auténticos negativos es del 78,90%. De los verdaderos.

La precisión, es decir, los datos clasificados como positivos y que realmente lo son es del 78,31%.



```
## [1] 0.8619569
```

Vemos como la curva ROC nos da un valor próxima a la esquina superior derecha y un área del 0.86, próximo a 1. Lo que indica que el modelo predice bien los datos.

Se observa que el modelo es bueno prediciendo si los pasajeros han desaparecido o no.

5 Tablas y gráficas

Se han ido desarrollando y comentado las tablas y gráficas a lo largo de toda la memoria de la práctica.

6 Resolución del problema y conclusiones.

El objetivo que se buscaba lograr con el proyecto es el de obtener más información acerca de los datos de los pasajeros del crucero Intergaláctico denominado Titanic. Hola además, se pretendía que a partir del dataset dado se pudiera entrenar un modelo de regresión logística supervisado. Este modelo tenía por objeto y predecir si los pasajeros habían sido transportados o no para que la tripulación encargada del rescate pudiera centrar sus esfuerzos en las personas que han sido transportadas.

Se puede observar que hay algunos campos que presentan valores nulos y se analizan los posibles outliers, lo cual empeorará la calidad de los análisis. Por lo que para ello se lleva a cabo al tareas de limpieza de datos.

Se observa que del conjunto de datos utilizados para el entrenamiento hay aproximadamente la misma que han sido transportados y que no han sido transportados. También se observa que la mayoría de los pasajeros tiene un gasto con valores cercanos a cero o incluso nulos. Se detecta una correlación entre las variables *CabinSide* y *Transported*, una gran cantidad de pasajeros que estaban en el lado *S* han sido transportados mientras los que pertenecían el lado *P* no lo han sido. Se observa también cierta tendencia entre las variables *CabinSide* y *CryoSleep* aunque no es tan claro como en el caso anterior.

Se observa cómo las variables numéricas no siguen una distribución normal y además no presentan homocedasticidad cuando comparamos los Grupos definidos por la variable *Transported*. Es por lo que, para realizar el siguiente contraste de hipótesis se han tenido que utilizar test no paramétricos.

En los relativos a las propias estadísticas se obtienen las siguientes conclusiones.

En el análisis de Correlaciones, se quiere medir el grado de correlación entre las diferentes variables. Este análisis se realiza mediante el método de Spearman, ya que se ha visto anteriormente que las variables no cumplen la Normalidad ni la Homocedasticidad. Lo que se observa una vez se tienen los resultados de este análisis es que no parece haber ninguna variable altamente correlacionada; aunque es importante comentar que este análisis cobra sentido si se realiza a variables numéricas. Por tanto, sí podemos decir que entre las variables numéricas no existe una alta correlación. Esto no es contradictorio con el análisis realizado previamente, en el que se ha visto que podía haber relación entre la variable objetivo y otras variables categóricas.

En la prueba estadística de contrastes hipótesis se pretende medir si es diferente en la media del monto total gastado por las personas que han sido transportadas con la de el grupo de personas no transportadas. Para ello se lleva a cabo un contraste de hipótesis en el que la hipótesis nula será la igualdad de la media y la hipótesis alternativas, la no igualdad de estas. Se utilizará el contraste no paramétrico de test de sumas de rango de Wilcoxon. Esta arroja un P valor inferior al nivel de significancia de 0,05, por lo que se puede afirmar que la Cantidad total de dinero gastado por el Grupo de las personas que han sido transportadas y de las que no, no presentan la misma media. Por otro lado, se realiza un modelo de regresión logística que, en base las variables de interés. Ayuda a predecir si la persona ha sido transportada o no. Tras entrenar el modelo se Comprueba su bondad con el conjunto de datos reservados para el test y que no ha sido utilizado durante la fase de entrenamiento y se obtiene una precisión del 79,17%. Así como unos valores de sensibilidad del 79,45%, de especificidad del 78,90% y de precisión del 78,31%. El área que deja debajo la curva ROC es de 0,8619. Por lo que podemos concluir que el modelo es útil y ayuda a predecir los casos en los que se ha producido transporte.

El uso del modelo, así como los datos recabados en los otros 3 paramétricos y estudios del conjunto de datos nos permiten responder a las preguntas de investigación. Lo que ayudará a centrar los esfuerzos y maximizar el número de vidas salvadas.

7 Código

El código se ha ido desarrollando a lo largo de este material en formato PDF. Es código Desarrollado en lenguaje R, Aparte, se proporcionará un script de R en el que solamente se incluye el código.

Table 2: Tabla de contribuciones

Apartado	Contribución
Apartado 1	Juan Luis González Rodríguez
	Rocío González Martínez
Apartado 2	Rocío González Martínez
	Juan Luis González Rodríguez
Apartado 3	Juan Luis González Rodríguez
	Rocío González Martínez
Apartado 4	Rocío González Martínez
	Juan Luis González Rodríguez
Apartado 5	Juan Luis González Rodríguez
	Rocío González Martínez
Apartado 6	Rocío González Martínez
	Juan Luis González Rodríguez
Apartado 7	Juan Luis González Rodríguez
	Rocío González Martínez

- [1] Kaggle, “Spaceship titanic.” kaggle.com; Kaggle, 2022.Available: <https://www.kaggle.com/competitions/spaceship-titanic/overview>